

Bilag 3 - Valg af AI-model

Dette bilag dokumenterer de testede AI-modeller, der anvendes i projektet til at analysere og klassificere EEG/EMG-data. Ligeledes er træningstiden og præcisionen af hver model undersøgt, for at jeg kan vælge den bedste model, der skal bruges til forsøget med egne biosignaler.

Hver model har en kort beskrivelse af dens arkitektur og træningsproces. Efter dette nævnes kort præcisionen af hver AI-model, og slutvist opsummeres modellernes præstationer på tværs af hinanden, således den bedste model kan vælges til projektet.

Bilaget er opdelt i to:

- 1) En Journal over hvordan AI-modellerne blev testet
- 2) Overblik og koder til de forskellige AI-modeller.

Slutvist konkluderes hvilken AI-model der vælges til projektet

1 Journal: Ortosis armbevægelse, m. off. data

Udført af: Tobias Bendix Nielsen

Formål: Teste prototype af AI-model på offentligt data

Før eksperimentet

1,1) Indledende idéer og hypoteser

(Hvilke spørgsmål kan undersøges, hvilke(n) sammenhæng(e) forventer I at se og hvorfor og hvilke eksperiment(er) kan I så lave for at besvare disse spørgsmål)

Spørgsmål:

1. Kan en AI-model bruges til at forudsige bevægelse og ikke-bevægelse baseret på EEG- og EMG-data fra personer?
2. Hvordan kan modellen optimeres for at forbedre nøjagtigheden?

Forventningen var at finde en moderat sammenhæng mellem EEG og EMG, selvom datasættene stammer fra forskellige personer med individuelle hjernestrukturer. Hypotesen var, at modellen kunne forudsige bevægelse og ikke-bevægelse af data, og skabe et grundlag for videre optimering og anvendelse hos Parkinsons-patienter.

I projektets startfase blev data fra tidligere undersøgelser (Kueper et al., 2024) anvendt til at teste og iterere AI-modellen. Alle beskrivelser af metoden i denne journal er derfor lånt fra artiklen.

1,2) Metodebeskrivelse

(Beskriv hvordan I vil udføre eksperimentet, brug meget gerne en tegning. Argumenter for variabelkontrol. *Dette afsnit skal gøre at I kan lave en tabel i Excel med en kolonne til jeres uafhængige variabel og en kolonne til jeres afhængige variable, sådan at I er klar til at notere måleresultater*)

1,2,1) Eksperimentel opsætning

Forsøgspersoner blev instrueret til at udføre 15 gentagelser af fleksion og ekstension med højre arm. EEG-data blev registreret fra 64 kanaler, hvor jeg i min databehandling fokuserede på C3, C4 og Cz, som er relevante for den motoriske cortex. EMG-data blev optaget fra følgende muskler:

- M. biceps brachii
- M. triceps brachii (lateral og longus)
- M. flexor digitorum superficialis

For at minimere øjenartefakter blev forsøgspersonerne bedt om at fokusere på et sort kryds under eksperimentet.

Variabelkontrol:

- Elektroder blev placeret i henhold til det internationale 10 / 20 system, og standardprotokoller for at sikre konsistente målinger
- Data uden støj og bevidste fejl fra ortosen blev anvendt for at etablere en baseline og minimere støj

1,2,2) Materialer/apparatur

EEG-system:

- LiveAmp64 med 64 kanaler fra Brain Products GmbH
- ActiCap slim elektrode-system
- Samplingrate: 500 Hz
- Referenceelektrode: FCz, ground: AFz

EMG-system:

- ANT mini eego amplifier
- Samplingrate: 1000 Hz

- Bipolare elektroder placeret efter SENIAM-guidelines

Ortosis:

- Aktiv albueortose med torque-sensorer.

Synkronisering:

- Event Trigger Board til præcis justering af EEG- og EMG-data.

1,2,3) Sikkerhedsmæssige overvejelser


(Er der nogle sikkerhedsaspekter der skal tages hensyn til, enten over for deltagende personer, udstyr eller for eksperimentets resultat)

Personerne skulle ikke lave voldsomme bevægelser, og blev bedt om at forholde sig i ro.

1,3) Efter eksperimentet:

1,3,1) Fremgangsmåden

Dataene blev indsamlet fra otte forsøgspersoner med elektroder placeret på hovedbunden samt på nævnte muskler på begge arme. Disse muskler er involveret i armens sammentrækning og udstrækning. På figuren herunder ses musklernes placering i armen



Figur 1: Placering af de forskellige muskler, der placeres elektroder på¹

Forsøgspersonerne gennemførte 15 gentagelser af udstrækning og sammentrækning med højre arm, mens de stod stille og fokuserede på et sort kryds på en væg for at minimere øjenartefakter i EEG-data. Eksperimentet blev igangsat med en verbal stimuli fra forsøgslederen. Data blev optaget uden fejl induceret af ortosen for at etablere en baseline til

¹ Lånt af <https://www.getbodysmart.com/arm-muscles/>

prototypen. I projektet anvendes kun data uden fejl induceret af ortosen, for så vidt som muligt at afspejle virkeligheden når man bevæger armen.

EEG-data blev optaget med en samplingrate på 500 Hz og et hardwarebandpass fra 0,0 til 131,0 Hz. EMG-data blev optaget med en samplingrate på 1000 Hz, og elektroderne blev placeret i henhold til SENIAM-guidelines. Synkroniseringen mellem EEG- og EMG-data blev opnået med en Event Trigger Board, der muliggjorde præcis justering af de to datastreams, selvom de var indsamlet med forskellige systemer og samplingrater. Den gennemsnitlige tidsforskel mellem datasæt var under 8,5 ms.

1,3,2) AI-modeller

I bunden af bilaget, ligger alle koder for hver af de anvendte AI-modeller. Modellerne blev trænet på data fra (Kueper, et al., 2024), hvor EEG_AA56D og EMG_AA56D ikke er inkluderet, da disse filer var korrupte. Kun kanalerne EEG-data fra C3, C4 og Cz var anvendt, og de 4 første kanaler for EMG ligeledes. Dette skyldes projektet undersøger den motoriske cortex, mens de resterende 4 kanaler i EMG, ikke havde relevante signaler (armen bevægedes ikke). Ligeledes undersøgte jeg tidsvinduet 30 til 210 sekunder i data, da signaler før dette var meget støjfyldt. Jeg synkroniserede også EEG med EMG, og kiggede på EEG signaler 200 ms før en bevægelse (bestemt ved en tærskelværdi for EMG), da jeg antog det at svare til bevægelsesintentionen i EEG.

Validering: K-fold cross-validation sikrer robusthed.

Præcision: Der anvendes confusion-matrix som præcisionsmetrik for alle modeller, hvilket visualiseres med en ROC-kurve.

1,4) Observationer/Måleresultater/Databehandling

(Opskriv observationer og måleresultater opnået under eksperimentet. Hvilke sammenhænge viser jeres observationer og/eller måleresultater? Hvad viste undersøgelsen?

På baggrund af EMG og EEG data fra (Kueper, et al., 2024), blev mine AI-modeller trænet på dette. For at sammenligne AI-modeller på tværs af hinanden, vurderes de på: præcision, hastighed. Feltet markeret med grønt var bedst til pågældende metrik på tværs af modeller, og feltet markeret med rødt var værst. Forneden ses AUC, præcision og tiden for hver af AI-modellerne. Effektiviteten definerede jeg som:

$$\text{Effektivitet} = \left(\alpha \cdot \frac{\text{Præcision}^2}{\text{Præcision}_{\max}} + \beta \cdot \text{AUC} \right) \cdot \left(1 - \gamma \cdot \frac{\log(\text{tid})}{\log(\text{tid}_{\max})} \right)$$


Hvor: $\alpha = 0,8$, $\beta = 0,5$, $\gamma = 0,7$, og

Præcision_{\max} er den højeste præcision på tværs af alle modeller
 tid_{\max} er den længste tid på tværs af alle modeller.

På den måde vægtes præcisionen højest, men tiden er samtidig væsentlig.
En effektivitet tættere på 100%, bevidner en bedre AI-model.

AI-model	Præcision	Tid / s	AUC	Effektivitet
LSTM-CNN	99,92%	3655	100,00%	51,85%
LSTM-RNN	97,58%	14165,18	99,33%	37,75%
CNN	100,00%	1329	100,00%	61,53%
Transformer	98,50%	645	99,97%	67,15%
SVM	67,29%	8	69,48%	60,16%
A-SVM	85,67%	57	93,36%	74,19%
DeepConvNet	99,87%	1063	100,00%	63,55%

Figur 2: Tabel med data fra forsøget



Figur 3: Søjlediagram over effektiviteten af modellerne

1,4,1) Belæg

(Hvilke resultater og fortolkninger kan I bruge som argumentation for jeres konklusioner. Her skal man gentage de vigtigste resultater, sådan at det er tydeligt hvad man er kommet frem til og hvor gode ens resultater er, dette gør at man nemmere kan gå til diskussionen)

Af resultaterne ses det, at

- **LSTM-RNN** og **LSTM-CNN** klarer sig dårligt, grundet deres kompleksitet og træningstid

- **SVM**-havde den laveste præcision på 69,48%, og blev derfor fravalgt
- **CNN** og **DeepConvNet**, var hurtige og præcise, men er mindre egnede til tidsafhængige signaler som EEG/EMG. Derfor anvendes disse heller ikke.
- **A-SVM** havde højeste effektivitet, men blev fravalgt pga. begrænset litteratur og grundet transformer-arkitekturer er cutting-edge teknologi. Ligeledes var dens præcision 13 procentpoint lavere end Transformerens.

Derfor vurderes Transformer-modellen til at være den bedste model videre i projektet. Dette skyldes dens høje effektivitet, samt der eksisterer meget litteratur online om denne, som gør det nævner at videreudvikle modellen. Derfor anvendes Transformer-modellen videre i projektet, og bliver den model, der skal forudsige mine bevægelser baseret kun på tankerne.

1,5) Diskussion

(Svarer jeres resultater til det som andre (forskere, tabelværdier, naturkonstanter) har fundet? Inddrag eventuelle usikkerheder og fejlkilder der har haft betydning for eksperimentet)

I hidtil forsøg, er AI-modellen trænet på ikke-Parkinsons-data samt trænet på 8 forskellige hjerner. Dette medfører dataet hverken afspejler egentlige patienters bevægelser, samt er det ikke individualiseret og tilrettelagt en enkelt person. Der er nemlig stor forskel på strukturen af menneskers hjerner, og dermed er de elektriske impulser også forskellig fra person til person.

I mit fremtidige eksperiment bliver målingerne mere støjfyldte og mindre præcise, da jeg vil anvende mit hjemmebyggede EEG/EMG/IMU-opsætning, som ikke har samme præcision som det anvendt hos forskerne bag artiklen.

1,6) Refleksion

(Hvad er svaret på de(t) stillede spørgsmål. Hvad har I lært, såvel eksperimentelt som teoretisk?)

Denne journal viser, at en AI-model kan forudsige muskelbevægelser baseret på EEG og EMG, men der er plads til forbedring. Modellen repræsenterer et vigtigt første skridt mod udviklingen af teknologi til at støtte Parkinsons-patienter. Fremtidige iterationer bør inkludere mere præcise data, avancerede metoder og en større grad af individualisering for at sikre klinisk anvendelighed.

2 Oversigt over AI-modeller

I projektet er anvendt mange forskellige AI-modeller til klassifikation af EEG/EMG-data. Disse inkluderer:

- Model 1: LSTM-CNN
- Model 2: LSTM
- Model 3: CNN
- Model 4: Transformer
- Model 5: SVM
- Model 6: A-SVM
- Model 7: DeepConvNet

Modellerne har alle k-kryds-validering, AUC, confusion-matrix og præcision, som deres præcisionsmetrikker. På dette link kan modellerne findes:

<https://github.com/TobiasBN1005/From-thought-to-movement->

3) Beskrivelse af AI-modeller

2,1) LSTM-CNN

Denne model er beskrevet nærmere i bilag 5. Men kort sagt, så udnyttes mønstergenkendelsesevnerne fra CNN sammen med langtidshukommelsen fra LSTM, til at forudsige EMG-signaler og bevægelser.

2,1,2) LSTM-RNN

Denne type af AI-model er beskrevet nærmere i bilag 5. Men kort sagt, så er en LSTM (Long Short-Term Memory) en type rekurrent neuralt netværk (RNN), der kan huske tidligere information i længere tid. Den bruges især til tidsseriedata som EEG og EMG, fordi den kan lære mønstre over tid og forudsige fremtidige værdier baseret på tidligere input.

2,1,3) CNN

Denne type af AI-model er beskrevet nærmere i bilag 5. Men kort sagt, så er en CNN (Convolutional Neural Network) en type neuralt netværk, der er særligt god til mønstergenkendelse i data. Den bruges ofte til billed- og signalbehandling, da den kan identificere vigtige træk ved at anvende filtre, der fokuserer på lokale strukturer i inputdata.

2,1,4) Transformer

Denne type af AI-model er beskrevet nærmere i bilag 5. Men kort sagt, så er en Transformer et neuralt netværk, der analyserer data parallelt ved hjælp af self-attention, så det kan finde vigtige mønstre i selv lange sekvenser. Den bruges ofte til at kombinere forskellige typer data

(f.eks. EEG, EMG og IMU), som først forbehandles og omdannes til vektorer. Disse behandles i flere lag for at lære komplekse sammenhænge og bruges derefter til fx at klassificere bevægelser.

2,1,5) SVM

En klassifikationsalgoritme, der adskiller data i klasser ved at finde en optimal hyperplan. Support vectors: datapunkter tættest på optimale hyperplan, som definerer marginen der støtter og bestemmer hyperplanet.

Hyperplan: beslutningsgrænsen som adskiller datasæt mest muligt med størst margin, godt til at klassificere data. Hvis data ikke er lineære, anvendes kernefunktion (kernel), som projicerer data til et højere dimensionalt rum, hvor data nu bliver lineære separable.

God til binær klassifikation, men kan også bruges til flere klasser.

Bruges ofte i biomedicinsk signalbehandling

2,1,6) Adaptive Support Vector Machine (A-SVM)

En forbedret version af SVM, der kan tilpasse sig nye data, hvor hyperplan opdateres løbende m. ny data.

- Hvis punkter ikke påvirker marginen: samme hyperplan
- Hvis punkter påvirker marginen (de bliver support vectors) → justering af hyperplan → optimal margin.

Nyttig i dynamiske miljøer, hvor data ændrer sig over tid.

Forskel ml. A-SVM og SVM:

Tilpasning til ny data:

- SVM: trænes én gang på en fast mængde data, og er derefter låst
- A-SVM: kan opdatere sin beslutningsgrænse løbende, eftersom ny data tilføjes (dynamisk)

Afhængighed af statisk træning:

- SVM: er afhængig af, at data er repræsentativt for hele problemet
- A-SVM: kan genlære fra nye eksempler, uden at træne modellen helt fra bunds

Tidligere modeller som base:

- A-SVM bygger videre på en tidligere SVM-model, mens SVM hele skal begynde forfra.

A-SVM kan tilpasse sig og forblive præcis, selv hvis data ændrer sig over tid (f.eks. hvis en persons muskelreaktioner ændrer sig)

2,1,7) DeepConvNet

DeepConvNet er ligesom et traditionelt CNN, men har bare flere lag af arrays.